


Week 4 Homework

Question 1 — Choose the Right Genomic Assay (25 pts)

Figure:

Q1 Experimental strategy: which mechanism raises Gene X?



1. Reasoning before AI

我把问题先拆开: "Gene X 在疾病组相对健康对照上调"是群体层面的表达差异, 不是"某个人携带某个致病等位基因"。列出的五类机制分属不同层次 (DNA 序列、染色质可及性、TF 结合/组蛋白修饰、DNA 甲基化、enhancer-promoter 接触), 每一层的证据形式不同, 没有任何单一 assay 能同时排除其余四类。

我选的第一刀是 ATAC-seq (疾病相关细胞类型, disease vs control, ≥ 4 个生物学重复/组, 与现有 RNA-seq 用同一批样本和同一细胞分选方案), 理由:

1. 它测的是最上游、假设最少的那一层——"这段 DNA 在体内是否可被 transposase 接近"。不需要抗体（避开 ChIP/CUT&Tag 的 antibody specificity 问题），不需要亚硫酸氢盐转化（避开 WGBS 的化学分辨率问题），一次实验给出全基因组候选调控元件，正好回答"Gene X 附近有没有正在变化的候选元件"。
2. 它给出可继续追问的坐标。拿到 differential accessibility 的 peak 之后，才能有指向性地做 H3K27ac / TF occupancy、看 CpG、问 3D 接触、设计 MPRA 与 CRISPR。反过来先做 Hi-C 或 WGBS，成本高、得到的是关联，且无法定位到元件。
3. 它本身就能分流机制（见下表）：若 Gene X 邻近元件 accessibility 上升且伴随 H3K27ac 上升 → 偏向 enhancer/promoter 活性改变；若 accessibility 不变而 mRNA 上升 → 更可能是转录后稳定性、拷贝数或 trans 层面（TF 活性/丰度）变化，此时应转向 RNA 层面，而不是继续加做染色质实验。
4. 例外我写清楚：如果表型其实是罕见/家族性的（有家系、发病早、共分离），第一刀应当是 WGS/WES（或 WGS + 家系），那时"一个高外显的编码变异"是最简约假设。本题是"疾病组 vs 健康对照组"的群体设计，所以我把 WGS/WES 放在"排除编码原因/CNV"的位置，而不是第一位。

完整策略：

步骤	Assay	它测什么（决定它的证据地位）	它不能证明什么	结果如何决定下一步
0	重申现有 RNA-seq + 公共 eQTL/caQTL (GTEx、ENCODE)	表达差异是否稳健；Gene X 是否已有遗传锚点	不是新实验，只能生成假设	若有 caQTL/eQTL 共定位 → 把候选窗口缩到具体碱基
1	ATAC-seq (disease vs control, 同细胞类型, ≥4/组)	染色质可及性 (Tn5 插入)	不等于 TF 身份；不等于"激活"	有 differential peak → 进第 2 步；无 → 转第 6 步 (trans/转录后)
2	H3K27ac CUT&Tag (同一批核) + TF CUT&RUN (按 motif 预测的 TF, 带 input/IgG 对照)	活跃增强子标记；某个蛋白的占据	占据 ≠ 功能；抗体特异性是主要风险	元件为 active (H3K27ac+) → 进第 3/4 步；若为 poised/H3K27me3 → 换假说
3	WGBS / EM-seq	单位点 5mC 比例	甲基化变化本身不说明因果方向	元件低甲基化 → 支持"活跃"；高甲基化 → 换"沉默/印记"

				"假说"
4	Hi-C / Micro-C (或 promoter Capture-C)	空间接触频率	邻近 ≠ 调控	元件–Gene X 启动子特异接触 → 进第 5/7 步; 无接触 → 换目标基因
5	CAGE / RAMPAGE	TSS 簇与启动子使用	不证明 enhancer 身份	若发现 alternative promoter → 机制是 "启动子切换"而非"增强子变强"
6	MPRA / STARR-seq (ref vs alt 等位)	序列本身的报告活性 (allele-specific)	质粒环境 ≠ 天然位点	等位差异显著 → 该碱基是功能位点; 无差异 → 该 SNP 不是因果碱基
7	CRISPRi / CRISPRa / enhancer deletion + rescue	天然位点上元件是否必需	需要好的对照 (见 Q3)	这是唯一能把 correlation 变成 causality 的一步

2. AI-assisted workflow

我给 agent 的 prompt 是 **critique-first**, 明确禁止它替我重做设计:

*"I have already decided to run ATAC-seq first for a gene upregulated in disease vs control, with the possible mechanisms being a regulatory variant, chromatin accessibility, TF/histone changes, methylation, or enhancer–promoter contact. Do **not** redesign from scratch. Instead: (1) list the strongest ways my chosen first assay could mislead me, (2) tell me which of my 8 steps is the weakest link for distinguishing the mechanisms, (3) tell me what sample-size/design detail would make the ATAC comparison invalid, and (4) state which conclusions I would be unable to reach even if the whole workflow succeeds."*

AI 提出的批评里我采纳的部分:

- ATAC 无法区分"激活型"与"抑制型"染色质变化 (peak 变化本身没有方向性) → 我在策略里强制加了 H3K27ac (active mark) 与 H3K27me3 的分流 (表 1 第 2 步)。
- bulk 组织 ATAC 会把细胞比例变化误读成"可及性变化": 疾病组若炎症细胞浸润增加, peak 变化可以完全来自细胞组成 → 我加了 FACS 分选/单细胞 multiome 作为备选, 并把"细胞比例"写进混杂清单。
- ATAC 不能给出 Tn5 上的 TF 身份 → 必须有 motif 预测 + CUT&RUN 两步, 且 motif 只能是 predicted, 不能当 measured 证据。
- 样本量: bulk ATAC 组间比较若只有 1 个 donor/组, 无法把生物学重复与技术重复分开 → 我定为 ≥4 donors/组, 生物学重复贯穿全流程。

- 最弱的一环：AI 指出"元件-基因的配对"是整条链最弱的一环（accessibility 和 RNA 都在，但两者是否同一因果链未定）→ 所以 final conclusion 里的必需实验是扰动天然位点，而不是再加一个组学层。

我没有采纳的：AI 一开始建议"先做 MPRA 筛所有候选元件再定位点"。MPRA 便宜但测的是质粒上的序列活性；在我连"体内哪个元件在变"都还没确定时，MPRA 的候选集无从定义——这属于把便宜实验放在错误的上游位置。我改为"先 ATAC 定位 → 再 MPRA 验证具体碱基"。

3. Verification

我的主张	核对来源（版本/访问日期）	结果
ATAC-seq 读出的是 transposase 可及性，不等于 TF 身份	ENCODE portal assay 标准与 ATAC-seq 数据处理说明 (encodeproject.org, 2026-09-20 访问)；课程 reading 第 8 节 "assay to evidence pathway"	一致：reading 的局限列直接写 "Accessibility is not TF identity"
H3K27ac 是 active enhancer 相关标记，但占据 ≠ 功能	ENCODE histone ChIP-seq 标准；SCREEN/ENCODE cCRE 注释说明	一致：SCREEN 只能给"候选 cis-regulatory element"，不能给因果
CAGE/RAMPAGE 才是 TSS 定位的标准读出	FANTOM5 与 EPDnew (epd.expasy.org) 说明	一致：TSS 依赖细胞状态与转录本检测
Hi-C/Micro-C 的 read pair 只代表"被捕获的邻近事件"	4DN 数据门户 (data.4dnucleome.org) 关于接触矩阵与归一化的说明	一致："proximity is not regulatory causality"，且必须报告 normalized/balanced 与 bin size
扰动 (CRISPRi/deletion) 是区分相关与因果的必要一步	课程 reading 第 8 节表格 ("Is a native element required?" → CRISPRi/deletion/allele editing)；第 19 节 ("Disrupting the element and rescuing... address different links")	一致，并据此把 rescue 写进设计
WGBS/EM-seq 的化学分辨率与"甲基化 ≠ 因果方向"	课程 reading 第 16 节；EM-seq 官方化学说明	一致

4. Final conclusion

Each assay in this design measures exactly one link and therefore cannot be read as proof of the mechanism it suggests. WGS/WES measures inherited sequence and copy number; it can show a candidate regulatory allele but not that the allele changes activity. ATAC-seq measures transposase access, so it locates candidate elements but says nothing about transcription-factor identity or about whether the change activates or represses. ChIP-seq, CUT&Tag and CUT&RUN measure enrichment of a chosen protein or mark; they are limited by antibody specificity and by occupancy not equalling function. WGBS and EM-seq measure 5-methylcytosine per site, but direction of causality and the


contribution of cell composition remain open. CAGE and RAMPAGE measure transcription start sites and promoter usage, not enhancer identity. Hi-C and Micro-C measure captured proximity, which is not regulation. RNA-seq measures steady-state transcript levels, which lie downstream of regulation. MPRA and STARR-seq measure sequence-intrinsic reporter activity in a plasmid context, not the native locus. CRISPR interference, activation, deletion, and loop-anchor perturbation are the only steps that test necessity and sufficiency at the endogenous locus; the others supply the candidate, the mechanism class, and the controls that make the perturbation interpretable. Complements: ATAC with H3K27ac classifies state; ATAC with Hi-C links element to target; methylation with accessibility separates active from silenced; reporter with perturbation separates allele effect from locus requirement.

The biological question chooses the assay because... the question is "which regulatory mechanism raises Gene X in a disease group", so the first assay must measure the mechanism layer with the fewest assumptions and the widest coverage (ATAC-seq), every later assay must be chosen to rule out one remaining mechanism class (H3K27ac / TF occupancy, methylation, promoter usage, 3D contact), and the design is only complete when a perturbation test at the native locus can distinguish the mechanism adopted from the mechanisms still consistent with the same correlative data.


Question 2 — From FASTQ to a Trustworthy Analysis Workflow (25 pts)

Figures:

Q2 Workflow: raw paired-end reads to an interpretable genomic result



Q2 evidence panel: S01 synthetic PE demo measured from the raw FASTQ (120 pairs x 80 bp) - my numbers, not the snapshot's



1. Reasoning before AI

我先假定 assay = WGS (germline, PE) ——manifest 里 S01/S02 是 WGS, S03–S08 是 RNA-seq/ATAC/ChIP, 所以 QC 判读必须按 assay 分开, 不能一套阈值走到底。下面是我自己画的流程和每一步"为什么存在":

Step	目的	产出/检查点
1 FASTQ QC	把技术信号 (adapter、质量崩塌、重复、污染) 从生物学信号里摘出来	FastQC/MultiQC 报告 → 决定是否 trim → trim 后必须重跑 QC

2 Reference	固定坐标系：一次选定 build + annotation release	GRCh38 + GENCODE 指定 release; index/.dict; 记录 release 号
3 Alignment	决定一条 read 能"声称"什么	WGS: BWA-MEM2 (保留 read group) ; BAM 存比对
4 Mapped-read processing	决定一个 genotype 有多少独立支持	sort/index、duplicate marking (按 caller 要求)、flagstat/covstats
5 Downstream (assay-specific)	得到可比较的定量结果	germline VCF (+joint genotyping/gVCF)、bcftools norm -m -any 归一化; RNA: counts; ATAC: peaks
6 Annotation	把变异/区间连到版本化的转录本与人群资源	VEP (指定 transcript set)、gnomAD AF、ClinVar、调控注释 (ENCODE/SCREEN、GTEx)
7 Visualization	用眼睛检查统计量检查不到的东西	IGV/IGV.js 看 read、覆盖度分布、PCA/batch 图
8 Interpretation	把"数据"降级成"有边界的结论"	每个字段标注 measured / derived / predicted / inferred; 写出不能观测的部分

2. AI-assisted workflow

我给 agent 的 prompt 是 plan-first, 要求它先给计划、标注每步的 verification 依据, 再给命令:

"Plan-first: design a reproducible workflow from paired-end Illumina FASTQ to an interpretable genomic result for a small local workstation. For each of the 8 stages (QC, reference, alignment, post-alignment processing, assay-specific downstream, annotation, visualization, interpretation) give: the tool, the exact command shape, the output format, the checkpoint that proves the step worked, and the parameter I must justify rather than take from a default. Then, for FastQC, list which modules I must interpret for a WGS library and what a red flag looks like. Label every claim you are not certain about."

AI 产出的可直接使用的部分: BWA-MEM2 / samtools / bcftools norm / VEP 的命令骨架; samtools quickcheck、samtools flagstat、bcftools stats 作为 machine-readable checkpoint; GRCh38 + GENCODE 的固定方式; FastQC 模块清单。我在执行前改掉和补上的东西列在下面 3(b) 的 AI-audit 表里。

3. Verification

(a) FastQC 指标判读 (7 个模块) —— 用我自己的测量, 而不是只读 snapshot

本机没有 Java，因此没有 FastQC（作业允许读 fastqc_snapshot.tsv）。但我没有停在 snapshot 上：我直接从 data/demo_fastq/ 的 gz 读数复算了同样的模块（scripts/qc_demo_fastq.py, 120 pairs × 80 bp, R1+R2），逐条与 snapshot 对照：

Metric	我实测的值 (R1 / R2)	Snapshot 的说法	判读 (expected / red flag → 处理)
Per-base sequence quality	cycle 1 均值 Q36 → cycle 80 均值 Q27; 第 10 百分位自 ~cycle 50 起 = Q12; 18/120 (15.0%) 读数有 3' 崩塌; ≥Q30 碱基占 91.6%/91.7%	WARN, 3' median ~Q12 after cycle 50 on ~15% of R1	复现。Q12 落在箱线图下四分位而不是中位数——判读要看下四分位/10th pct, 不能只看均值; 处理: 3' 端 trim (fastp/Trimmomatic), trim 后重跑 QC
Per-sequence GC content	R1 均值 42.8% (R2 41.3%); 10.0% 读数 ≥60% GC (双峰高 GC 肩 ~78%)	WARN, mode ~41% + ~78% shoulder	复现。单峰偏移 = 污染/富集偏差; 这里是 10% 高 GC contaminant spike → 按污染处理, 回查文库来源
Adapter content	AGATCGGAAGAGC 自 cycle 68 起出现, R1/R2 各 15.0%	FAIL, ~15% of pairs, 3' 上升	复现。adapter 从 3' 抬起 = 插入片段短于读长 → trim 即可, 不代表样本失败
Sequence duplication levels	R1: 86/120 唯一序列, 重复比例 28.3%; 两条序列各占 15.0% (同一个 template 的两种形式); R2: 120/120 唯一	WARN, one template in ~15% of R1	复现 (R1 的 15%+15% 就是那一个 template)。WGS 下需 mark duplicates; RNA-seq 下高重复可以是正常表达特征, 判读必须按 assay
Overrepresented sequences	最高频序列 = 上述 template (15.0%), 其尾部就是 adapter 片段	FAIL, adapter fragment 在 top overrepresented	复现, 与 Adapter content 同一根因
Per-base N content	0 / 0 碱基	PASS ~0%	复现, 无 basecalling 崩塌
Sequence length distribution	全部 80 bp (均值 80)	PASS, 全部 80 bp	复现, 均匀 (合成数据的预期特征)

一个"先错后对"的过程。我第一版脚本把 per-base quality 的判定写成"per-cycle 中位数最小值", 结果是 Q29, 脚本自动打了 check (与 snapshot 不符)。原因是统计量选错了: 15% 的读数崩

到 Q12 不足以拉动整体中位数。改成按 FastQC 箱线图的方式算第 25/10 百分位后，cycle 80 的 p10 = Q12，与 snapshot 一致。→ 教训：判读一个模块之前，先确认这个模块报告的是哪个统计量（FastQC 的 per-base quality 以箱线图呈现分位数，不是均值）。


(b) AI-audit table

AI recommendation	My verification (doc / source)	Final decision
"用最新 GENCODE release 即可，build 默认 GRCh38"	Ensembl/GENCODE 发布页 (release 与 assembly 的对应关系，2026-09-20 访问)；且我在 Q4 的 Ensembl 双装配查询里实测到"同一坐标在两版里落在不同基因"	修改：不写"最新"，固定 release 号与 assembly 并写进 log；流程入口加一条断言——输入坐标必须声明 build (Q4 的表就是反例)
"所有样本统一 mark duplicates"	GATK/Picard 文档关于 duplicate marking 的前提与 caller 的配合；课程 reading: "mark or model duplicates according to the caller"	部分否决：WGS 做 markup；RNA-seq 不做（除非 UMI 方案），否则会把真实高表达基因当重复去掉
"FastQC 出现 FAIL 就剔除样本"	FastQC 模块说明 + 课程 cheat-sheet: Adapter content FAIL 属于可修复项	否决：FAIL 是动作指令 (trim/重跑 QC)，不是样本级判据；只有 trim 后仍不可修复的模块才进入样本剔除讨论
"trim 掉低质量碱基就能解决质量崩塌"	我的实测：崩塌是 15% 的读数在 3' 端系统性到 Q12，且分布在 cycle 50 之后；trim 能去掉受影响碱基，但不能恢复信息量	修改：trim → 重跑 QC → 统计受影响读数比例；若真实数据里比例高且集中在部分样本，必须回查文库/仪器，并考虑这些样本的变异检出灵敏度，而不是默认 "trim 完就没事"
"BWA-MEM2 用默认参数，直接进 calling"	samtools/bcftools/GATK 文档：read group、MD/NM tag、caller 对 BQSR 的要求；课程 reading 的 checkpoint 清单	修改：保留 read group、记录版本、加 samtools quickcheck + flagstat/covstats + bcftools stats 三个 checkpoint；callable territory 必须报出 ("PASS 记录不等于在那个位点可检出")
"用 R 载入 BAM 做可视化/SVA"	课程 reading 明确指出：R 不应载入高深度比对，终端工具才是对齐/排序/调用的正确层	采纳并写进分工：终端做重活，R/Bioconductor 做区间、统计、注释、整合与出图

4. Final conclusion

Figures:

Q2 evidence panel: S01 synthetic PE demo measured from the raw FASTQ (120 pairs x 80 bp) - my numbers, not the snapshot's




流程的可信性来自每一步都留下机器可读的检查点：QC 报告 → samtools quickcheck/flagstat → bcftools stats → 归一化后的 VCF + VEP 版本记录。命令返回 0 只说明命令跑完了，不说明结果对；所以每个 checkpoint 我都指定了要看的量（adapter 比例、重复率、mapQ 分布、插入片段、callable territory、Ti/Tv、缺失基因型比例），并且这些量必须在样本之间横向比较，而不是逐样本孤立判断。

The analyst, not the AI, is responsible for... choosing and pinning the reference assembly and annotation release, deciding which QC warnings are assay-appropriate rather than fatal, understanding and justifying every threshold and every exclusion (and never letting them change silently), verifying that a record's alleles and coordinates are valid on the named reference before it enters interpretation, and for stating which conclusions the assay cannot support; the AI can draft the commands, the code and the summaries, but it cannot be the evidence.

Question 3 — Integrate Multi-Omics Evidence into a Regulatory Hypothesis (25 pts)

Figure:

Q3 One locus, five layers, one perturbation: is element E a plausible enhancer of Gene Y?



1. Reasoning before AI

(a) ATAC-seq (accessibility) — measured: E 处有一个峰，疾病组比对照高 3.4 $\times$ (FDR 1e-6) ; Gene Y 启动子处峰基本不变。interpretation: E 所在区域在疾病条件下处于可接近状态 ("open")。missing: 细胞组成 (是否因细胞比例变化导致的假信号)、等位特异性 (杂合位点上是否只有一条染色体开放)、时间顺序。局限: 可接近 $\neq$ 活跃 $\neq$ 增强子。

(b) H3K27ac CUT&Tag (active mark) — measured: E 处 H3K27ac 信号同步升高; Gene Y 启动子处信号也高但变化较小。interpretation: E 的染色质状态是 active 而不是 poised/silenced。missing: 抗体特异性对照 (IgG/input 的富集比)、H3K27me3/H3K4me1 对照层 (用于排除 poised enhancer)。局限: 标记存在 $\neq$ 该元件调控 Gene Y。

(c) DNA methylation (WGBS/EM-seq) — measured: E 上的 CpG 平均甲基化 26%, 全基因组背景 71%; Gene Y 启动子低甲基化 (本来就低, 变化不显著)。interpretation: E 的低甲基化与其活跃状态一致 (甲基化与 enhancer 活性通常反向相关)。missing: allele-specific methylation、细胞类型分辨率 (bulk 平均)、甲基化的时间点。局限: 相关方向无法从这一层判定。

(d) Hi-C / Micro-C (3D contact) — measured: E–Gene Y 启动子的接触在两个条件下都存在, 疾病组接触强度高 **2.1×** (derived: 归一化后的 loop strength) 。interpretation: 两者处于同一空间邻域, 疾病条件下更靠近。missing: 接触的分辨率是否支持该 loop (bin size vs 距离)、是否在同一 TAD 内、接触是否必要。局限: proximity ≠ regulation; loop 存在也可能只是同一 TAD 的副产物。

(e) RNA-seq (expression) — measured: Gene Y mRNA 疾病组升高 2.1× (padj 4e-4, n=4 donors/group) ; 杂合个体中观察到等位表达不平衡 68:32。interpretation: 转录产物确实升高, 且等位不平衡提示存在顺式 (cis) 调控成分。missing: 蛋白水平/稳定性、是否只改变了一个转录本 (isoform) 、细胞类型特异性。

整合模型 (pre-AI) : 一个在疾病条件下变得可接近、带 active mark、低甲基化、并与 Gene Y 启动子发生接触的元件 E, 其变化与 Gene Y 的顺式表达升高方向一致 → E 是 Gene Y 的 candidate enhancer。但整条链的证据都是相关: 五层同时变化也可以由同一个上游原因造成 (例如疾病相关的 TF 环境改变, 同时打开 E、改变甲基化、并提高 Gene Y 转录) , 此时 E 是"伴随现象"而不是原因。

2. AI-assisted workflow

Prompt (摘要) :

"Below is my own read of five layers at one locus (ATAC, H3K27ac, methylation, Hi-C, RNA-seq). For each layer, split my text into three columns: (1) direct observations — only what the assay physically measured, (2) biological interpretations — claims about mechanism, (3) missing evidence — what would have to be measured to move (2) to (1). Do not add new data. Then give me the single strongest alternative explanation for the whole model that is consistent with all five layers, and tell me which one layer's 'missing evidence' most limits the causal claim."

AI 的分类里我用得上的部分: 它把"E 是 active enhancer"明确归到 interpretation (因为 active 是功能判断, 不是测量量) , 把"疾病条件下可接近"归到 observation (ATAC 直接测的是插入事件) , 把"E 与 Gene Y 在 3D 上接触"归到 observation + derived (接触是测到的, loop strength 2.1× 是归一化后算的) 。

3. Verification

我的说法	核对依据	结论
甲基化与 enhancer 活性反向相关, 但"低甲基化 ≠ 该元件活跃"	课程 reading 第 16 节 (methylation 化学与分辨率、DMR 需 replicate-aware 模型) ;	保留为"一致但非因果"

	DSS 文档	
Hi-C contact 需报告归一化状态与 bin size, 且"proximity is not regulatory causality"	4DN 门户说明; 课程 reading 第 18/23 节	图中 loop strength 标为 derived, 并要求 bin size 可见
H3K27ac 是 active mark, 但不能单独证明 enhancer 身份	ENCODE histone 标准; SCREEN cCRE 注释说明	补上 H3K4me1/H3K27me3 对照层作为 missing evidence
同一生物条件、同一批样本才是 "matched multi-omics"	课程 reading 第 19 节 (shared sample map、compatible assemblies; 明确警告不同 cohort/ 细胞类型不能称 matched)	在结论里加一条前提: 五层必须来自同一 donor 与同一细胞类型
扰动 + rescue 才能区分相关与因果	课程 reading 第 8/19 节	采纳为 final experiment

4. Final conclusion

Observations vs interpretations vs missing evidence

Layer	Direct observation (measured / derived)	Interpretation (推断, 未经扰动验证)	Missing evidence
ATAC-seq	E 处峰高疾病/对照 3.4× (FDR 1e-6) ; Gene Y 启动子无明显变化	E 在该条件下是可接近的候选调控元件	细胞组成校正; 等位特异性可及性 (AS-ATAC) ; 时间序列
H3K27ac	E 处 H3K27ac 升高, 与 accessibility 变化同向	E 处于 active 而非 poised 状态	H3K4me1/H3K27me3 对照; 抗体-对照富集比; 内源性 vs 质粒
Methylation	E 上 CpG 平均 26% vs 背景 71%	低甲基化与活跃状态一致	等位特异甲基化; 细胞类型分辨率; 变化的时间点
Hi-C / Micro-C	E-promoter 接触在两条条件均存在, 疾病组 loop strength 2.1× (derived)	E 与 Gene Y 启动子在同一空间邻域, 疾病条件下更近	分辨率/bin size 支撑; TAD 归属; 接触的必要性 (扰动)
RNA-seq	Gene Y +2.1× (padj 4e-4, n=4/组) ; 杂合子等位表达 68:32 (提示性)	Gene Y 转录产物升高, 且有顺式成分	蛋白水平; isoform 分辨; 排 mapping bias / CNV; 更多独立个体

Alternative explanation:

E 位于同一个 TAD 内、紧邻 Gene Y 的另一个基因 Z 的调控邻域; 疾病条件下, 上游的 TF 环境变化 (例如炎症信号导致的 TF 活性升高) 同时使 E 变开放、降低其甲基化、并提高

Gene Y 与 Z 的转录。E 与 Gene Y 启动子的接触只是同一 TAD 内的结构性邻近（两条件下都存在，只是强度随区室状态变化），因此 E 是伴随现象；真正驱动 Gene Y 的是 trans 层面的改变（或 Gene Y 近端启动子上未被检测的变异）。

这个替代解释与现有五层数据完全一致：它解释了"为什么五层同向变化"（共同上游）、"为什么接触在两条件下都存在"（结构邻近）、以及"为什么 Gene Y 启动子本身的 accessibility 没变"（不是启动子层面的开关）。它唯一不能解释的是等位表达不平衡 68:32——这也正是我要用实验去分辨的关键点。

Functional experiment:

Field	设计
Experiment type	CRISPRi (dCas9-KRAB) 靶向 E，平行做 enhancer deletion (两个独立 sgRNA 对)；并在杂合背景下争取等位分辨读端
被扰动的对象	天然位点上的元件 E（不是质粒、不是 Gene Y 启动子）
如果 E 是因果增强子	Gene Y RNA 下降（预期 30–60%）， 杂合子的两条等位中携带"活跃"等位的转录本下降更多 （allele-specific 下降），而旁基因 Z 不变；rescue（CRISPRa 或诱导型 Gene Y cDNA）恢复表型
如果替代解释成立	Gene Y 表达几乎不变（或两条等位同等下降 = 非顺式），而 Z 明显下降（E 是 Z 的元件）；或扰动后 Gene Y 仍随疾病信号变化（trans 驱动）
Key controls	(1) 非靶向 sgRNA；(2) 阳性对照 sgRNA（靶向 Gene Y 启动子本身，验证体系有效）；(3) 同 TAD 内无关元件 sgRNA（验证特异性）；(4) 每个元件 ≥2 个 sgRNA + ≥4 个生物学重复；(5) dCas9-KRAB 表达与 off-target 检查；(6) rescue 臂

~200-word integrated interpretation.

The five layers are concordant in direction but not in evidentiary status. ATAC-seq and H3K27ac CUT&Tag show that the candidate element E becomes accessible and carries an active chromatin mark in the disease condition, and WGBS shows the same element is hypomethylated relative to background, which is consistent with an active rather than a silenced element. Hi-C/Micro-C shows an E–promoter contact that exists in both conditions and is stronger in disease, so proximity cannot by itself establish regulation. RNA-seq shows the target gene is up 2.1-fold with a suggestive allelic imbalance, which points to a cis component but cannot distinguish a cis element from a cis-linked

variant. What is missing is the experiment that tests necessity: no layer measures whether E is required for Gene Y transcription in its native chromatin context, and none measures whether the accessibility change precedes the expression change. Reading these layers together therefore supports a hypothesis, not a mechanism. The residual risks I accept are cell-composition confounding in bulk ATAC, antibody specificity in CUT&Tag, and normalization/bin-size dependence of the contact map. The perturbation design is chosen specifically because it is the one measurement that discriminates between the enhancer hypothesis and a shared-upstream alternative.


The candidate element regulates Gene Y by acting as a cis-regulatory enhancer whose disease-associated increase in accessibility, H3K27ac and promoter contact raises Gene Y transcription in an allele-specific manner (rather than merely accompanying a shared upstream trans signal), and this can be tested by CRISPRi (dCas9-KRAB) and independent enhancer deletions at element E in the disease-relevant cell type, with non-targeting and promoter-targeting sgRNA controls, an unrelated-element control, allele-resolved RNA measurement in heterozygous cells, and rescue by CRISPRa or inducible Gene Y, expecting Gene Y down-regulation with allele-specific loss and no effect on the neighbouring gene if E is causal.

Question 4 — AI-Assisted Variant Prioritization (25 pts)

Figure: figures/Q4_prioritization.png

Code: scripts/q4_filter_variants.R (真实运行, 输出 logs/q4_filter_run.txt、results/q4_shortlist.tsv)

核对脚本: scripts/verify_variants_external.py、 scripts/check_ref_alleles.py、 scripts/vep_check_variants.py、 scripts/verify_population_frequency.py



1. Reasoning before AI:

Criterion	Rule / threshold	Rationale
FILTER	必须 == PASS	caller 自己都不接受的记录没有可

		解释性; LowQual/FAIL 记录只能回到读数层重看
Depth (DP)	≥ 20	germline 杂合位点 20× 是"看得见"的最低线; 低于此无法区分真杂合与丢失等位
Genotype quality (GQ)	≥ 30	Q30 ≈ 1/1000 的基因型错误率; GQ < 30 的位点在稀有变异场景下无法支撑结论
Allele frequency (AF)	≤ 0.01	罕见 (Mendelian 风格) 假说的上限; 高于 1% 的常见变异不适合做 "高外显致病" 解释 (但不排除其作为复杂性状风险因素)
Consequence	只保留 potentially impactful: stop_gained、frameshift_variant、splice_acceptor_variant、splice_donor_variant、start_lost、missense_variant	这些会改变蛋白/转录本的结构类后果; synonymous/intron/intergenic 在没有额外证据时不能进入 top

软性排序 (保留但降权) : ClinVar 标注 (Pathogenic > Conflicting > VUS > Likely_benign) ; DP/GQ 高 (DP≥50 且 GQ≥90) 加 1 分; 基因-疾病有效性 (gene-disease validity) 与表型匹配只作为 tie-breaker, 因为本题没有给表型。

2. AI-assisted workflow

Prompt (摘要, plan-first) :

"Plan-first: I will filter a 12-row synthetic variant table with these hard rules: FILTER == PASS, DP >= 20, GQ >= 30, AF <= 0.01, consequence in {stop_gained, frameshift, splice_acceptor, splice_donor, start_lost, missense}. Write an auditable R script that (1) applies the filters **sequentially** and logs which gene is dropped at each step, (2) asserts the row count and that the required columns exist, (3) builds a transparent evidence score = clinical tier + functional impact + quality bonus, and (4) writes a shortlist file. Do not add filters I did not specify. Also list every assumption my thresholds make that a reviewer could object to."

AI 的输出里我逐行审过、可以直接用的: sequential filter + 断言 + print 记录; 打分表结构; write_tsv 输出。

3. Verification

我用四个独立脚本核了整张表: Ensembl REST 双装配、NCBI db=snp / db=ClinVar、gnomAD r4 GraphQL、Ensembl VEP。结果如下 (全部可复现, 日志在 logs/) 。

(1) 坐标与基因 (`logs/q4\_external\_verification.txt`) ——同一张表混着两个装配

与 GRCh38 一致 (4 条)	与 GRCh37 一致 (3 条)	两版都能落进去 (2 条)	两版都对不上 (3 条)
TP53 chr17:7673803 (GRCh37 该位点是 DNAH2) ; BRCA2 chr13:32316461 (GRCh37 = RXFP2) ; HLA-A chr6:29942857 (GRCh37 无基因) ; ATM chr11:108323000 (GRCh37 = C11orf65)	CFTR chr7:117199644 (GRCh38 = ST7) ; LDLR chr19:11200200 (GRCh38 = DOCK6) ; KRAS chr12:25398284 (GRCh38 无基因——这 正是 KRAS codon-12 的经 典 GRCh37 坐标)	F5、MSH2 (基因跨度 大, 两版都包含该位 点, 无法仅凭落点判 定)	chr8:128750000 (GRCh38=CCDC26 / GRCh37=MYC) ; chrX:153870000 (GRCh38=L1CAM / GRCh37=IKBKGP1; MECP2 在 GRCh37 是 X:153,287,024- 153,363,212, 在 GRCh38 是 X:154,021,573- 154,137,103, 该位点两 版都不在 MECP2 内) ; chr4:88000000

→ 后果: 若流程假定单一装配, 至少有 3 条会被注释到完全错误的基因上; MECP2 那条的 "frameshift_variant" 在任一装配下都定位不到 MECP2。

(2) REF/ALT 是否真的存在于参考基因组 (`logs/q4\_ref\_allele\_check.txt`) ——5/12 条不存在表里的 REF 与参考碱基相比: GRCh38 相符 3/12, GRCh37 相符 5/12 (TP53 两版相同), 两版都不符 5/12 (BRCA2、F5、ATM、LDLR、MECP2)。例: chr13:32316461 GRCh38 的参考碱基是 A, 表里写 REF=C、ALT=T; chr1:169519049 两版参考碱基都是 T, 表里写 G>A。→ 这些记录不是"可疑变异", 而是"无法表示的记录": 不能写入 VCF, 也不能与任何数据库按等位比对。

(3) 独立注释 (Ensembl VEP, 双装配; `logs/q4\_vep\_check.txt`) ——标签只有 2/10 条能复现 (KRAS; F5 且仅在 GRCh37 下)

表里写的	VEP 独立注释 (正确装配)	判定
TP53 splice_acceptor_variant (NOTE: near a canonical splice junction)	missense_variant (ENST00000269305, MODERATE, SIFT deleterious); 到最近外显子 边界 35 bp	错。真实身份是 NM_000546.6:c.817C>T p.Arg273Cys (TP53 codon 273 热点), 不是 剪接位点变异
BRCA2 missense_variant	start_lost (HIGH, ENST00000380152 等); 该 碱基上的真实变异是 NM_000059.4:c.1A>G (起始 密码子)	错, 但方向是"更严重"; 注意表里那个等位 (C>T) 在该碱基上并不存在
KRAS missense_variant	missense_variant (MODERATE, SIFT deleterious / PolyPhen probably damaging)	对 (唯一一条完全可复现 的标签), GRCh37 坐标正 确
CFTR synonymous_variant + ClinVar Benign	GRCh37 = missense_variant (ENST00000003084); 该位点 3 bp 外就是 rs113993960 = ΔF508 (c.1521_1523del,	严重错 (把 CFTR 外显子 11 热点区域标成同义/良 性)

	ClinVar pathogenic, gnomAD exome AF 1.2e-2)	
MSH2 stop_gained + Pathogenic	GRCh37 = splice_donor_region_variant,intron_variant (LOW); GRCh38 = 某 NMD 转录本的 intron	错: 这条只因为 FILTER=LowQual 才被剔除
ATM missense_variant	GRCh38 = intron_variant (MODIFIER)	错
LDLR missense_variant	GRCh37 = 5_prime_UTR / upstream; GRCh38 = DOCK6 intron	错
HLA-A missense_variant	GRCh38 = synonymous_variant (LOW)	错
MECP2 frameshift_variant + Pathogenic	该位点无一装配在 MECP2 内 (GRCh38=L1CAM intron, GRCh37=IKBKGP1)	无法定位
F5 missense_variant (Benign)	GRCh38 = intron_variant; GRCh37 = missense (rs6025, Factor V Leiden)	只有在 GRCh37 下成立

(4) 人群频率与临床证据 (`logs/q4\_population\_frequency.txt`、dbSNP esummary、gnomAD r4)

位点	表里 AF / ClinVar 标签	权威值	判定
TP53 chr17:7673803 G>A	AF 1e-5 / Pathogenic, ClinVar ID VCV000012345	= rs121913343 (NC_000017.11:g.7673803G>A) 。 gnomAD r4: exome AF 4.1e-6 (6/1,461,760) , genome 0/152,318; dbSNP global MAF: TOMMO A=1e-5; ClinVar 提交含 pathogenic / likely pathogenic / uncertain; 同位置还有 COSMIC 记录	AF 量级正确; ClinVar 标签方向正确, 但给出的 ID 不存在 (见下)
KRAS chr12:25398284 C>A	AF 1.5e-4 / Conflicting	= rs121913529 (NC_000012.11:g.25398284C>A = `NM_004985.5:c.35G>T` p.Gly12Val) 。 gnomAD genome AF 1.3e-5; ClinVar: pathogenic / likely pathogenic / association / not provided	AF 比 gnomAD 高约 10x; ClinVar 确实"不统一", 标签方向正确
BRCA2 chr13:32316461 C>T	AF 1e-4 / VUS	该碱基上是 rs863224464 = NM_000059.4:c.1A>G (start_lost, ClinVar pathogenic, VCV000216026) ; 表里的 C>T 不是这个碱基上存在的等位	记录无效; 但"该位点"确实是一个致病性起始密码子变异位点
F5 chr1:169519049 G>A	AF 0.42 / Benign	= rs6025 (Factor V Leiden, NM_000130.5:c.1601G>A p.Arg534Gln) 。 gnomAD: exome AF 2.19e-2, genome 1.73e-2; dbSNP 各研究 MAF 0.59%–2.24%;	AF 高出观测值 20–70 倍 (该列不是真实人群频率); "Benign" 只是多个互相冲突标

		ClinVar: benign + pathogenic + risk factor + pathogenic low penetrance + drug response + conflicting	签之一, Leiden 本质是低外显风险变异 → 被 1% 上限正确剔除
表里全部 ClinVar ID	VCV000012345 / 67890 / 000777 / 000111	NCBI E-utilities esummary 返回 {"uids": []} → ClinVar 里查无此记录	占位符, 不能当证据引用

(5) R 里的真实运行 (`logs/q4\_filter\_run.txt`)

```
12 input records
FILTER == PASS      10 kept   (dropped: MSH2, HLA-A)
DP >= 20            9 kept   (dropped: MEC2P)
GQ >= 30            9 kept
AF <= 0.01          6 kept   (dropped: F5, ATM, intergenic chr8)
impactful consequence 4 kept   (dropped: CFTR, intergenic chr4)
survivors: TP53, BRCA2, LDLR, KRAS
record-validity gate 2 kept   (BRCA2, LDLR withdrawn: REF>ALT absent at that base)
final top 2: chr17:7673803 (TP53), chr12:25398284 (KRAS)
re-derivation queue: BRCA2, LDLR
```

4. Final conclusion:

5. ``chr17:7673803 G>A` (TP53, GRCh38) = `NM_000546.6:c.817C>T` p.Arg273Cys` — DP=80、GQ=99 通过质量门槛；记录本身在该装配上有效（REF 与 GRCh38 一致）；核对后身份明确：TP53 codon 273（DNA 结合域热点），gnomAD r4 exome AF 4.1e-6 / genome 0，ClinVar 有 pathogenic 与 likely pathogenic 提交，同位置有 COSMIC 记录。表里给它的标签（splice_acceptor）是错的，这一点必须写在结论里，因为它决定下一步做的是蛋白功能实验而不是剪接实验。
6. ``chr12:25398284 C>A` (KRAS, GRCh37) = `NM_004985.5:c.35G>T` p.Gly12Val` — DP=58、GQ=91；是整张表中唯一"坐标、REF、ALT、consequence 标签"四项都自治的记录；gnomAD genome AF 1.3e-5，ClinVar 有 pathogenic/likely pathogenic 提交但同时带 association 标签（不是统一的孟德尔证据）。它被保留是因为证据链最干净，但它同时带着最强的"somatic/假象"嫌疑。

chr13:32316461（BRCA2 起始密码子位点，该碱基上真实存在的 c.1A>G 在 ClinVar 是 pathogenic）与 chr19:11200200（LDLR）：它们不是被"降级"，而是被"退回"——表里的 REF/ALT 在参考基因组上不存在，无法写成有效记录。处理顺序是：先从 BAM 重新读取该位点的等位与读数（并把 build 钉死），再重新注释。BRCA2 这一条如果最终确认，其生物学影响（蛋白起始缺失）会排在 TP53 之上。

False-lead critique

AI 提出的质疑	科学上重要?	理由
注释标签本身是错的 (表里写 splice_acceptor, 实测是 missense)	Y	标签决定下一步实验: 按剪接位点去做 RT-PCR/minigene 会白做; 按错义要做 p53 反式激活/稳定性功能实验。但变异本身的身份 (p.Arg273Cys、codon 273 热点、超罕见) 在核对后是站得住的
没有 AD/allele balance, 无法排除 somatic/CHIP 或等位丢失	Y	表里连 sample 列都没有, 没有任何一条记录能被绑到 manifest 里的某个文库; 因此"这个人的 germline 变异"这一层根本无法验证 → 必须回到 BAM 看读数
C>T 转换在 CpG 上是最经典的测序假象/脱氨来源	Y	需要看局部是否是 CpG 以及链偏好; 这是读数层检查事项, 不是"因此不信"
表里的 ClinVar ID 不存在, 所以 "Pathogenic" 是编的	N	ID 是占位符, 但我用位置 → rsID → 真实 ClinVar 记录这条路独立核过 (rs121913343 确有 pathogenic/likely pathogenic 提交), 所以"致病性有提交支持"这个事实成立; 失效的是"用 ID 引用"这个动作
坐标装配不确定, 可能整个位点都错了	Y	我用双装配核对把它变成确定事实: 该位点在 GRCh38 下属于 TP53 且 REF (G) 与参考一致; 在 GRCh37 下则落到 DNAH2 → 必须声明 build, 而 p.Arg273Cys 的身份是在 GRCh38 下确立的
"AF 1e-5 可能只是这个合成表编的, 说明整个人群频率过滤不可信"	Y	这是唯一一条反噬我自己的过滤器的批评: F5 的 AF=0.42 已经证明这一列不是真实频率, 所以我的 AF ≤ 0.01 在这张表上只能当"演示", 真正的 AF 必须现场查 gnomAD/dbSNP (我在核对里补上了)

我接受为剩余风险的： (i) 没有 sample 归属与 AD，无法在表内完成 germline/somatic 判定；
(ii) AF 列不可信 → 频率过滤只能用外部查得的真实频率替代。**我不接受为风险的：** "ClinVar 标签因为是占位符 ID 所以无效"——位置级核对已经独立确认了致病性提交。

~200-word interpretation (Known evidence → computational inference → scientific hypothesis → required experiment)

Known evidence. The two records that survive both the content filters and the reference check are TP53 c.817C>T (p.Arg273Cys) at DP 80 / GQ 99 and KRAS c.35G>T (p.Gly12Val) at DP 58 / GQ 91. Both are rare in gnomAD (4.1e-6 exome and 1.3e-5 genome respectively) and both positions carry pathogenic submissions in ClinVar; the TP53 codon-273 position also has COSMIC records. The table's own labels do not survive verification: TP53 is annotated as a splice-acceptor variant but is a missense change, KRAS is the only label that reproduces, and two further records cannot be represented on the reference at all. **Computational inference.** VEP in both assemblies places both variants in the correct gene only under a declared build, and both are predicted deleterious (SIFT; PolyPhen probably damaging for KRAS). A germline KRAS codon-12 substitution is more plausibly somatic or clonal than causal, whereas TP53 R273C is a canonical germline hotspot. **Scientific hypothesis.** The TP53 missense may impair p53 DNA-binding and transactivation, contributing to the phenotype, while the KRAS record may be a somatic or artefactual passenger. **Required experiment.** Read-level review (strand, allele balance, CpG context, matched tissue), then a p53 transactivation or stability assay with an isogenic wild-type control, and orthogonal confirmation in an independent sample or tissue before any clinical framing.

***Variant** chr17:7673803 G>A (TP53 NM_000546.6:c.817C>T, p.Arg273Cys) **may influence** p53-dependent transcriptional response and disease risk **by affecting** the DNA-binding surface at codon 273 (a documented mutation hotspot); **this can be tested by** read-level confirmation of the call (allele balance, strand bias, matched tissue), an isogenic p53 transactivation/stability assay with wild-type rescue, and replication in an independent sample. The KRAS c.35G>T (p.Gly12Val) record is carried forward in parallel but must first be shown to be germline rather than somatic.*

Appendix — 复现方式与代码

A. 环境与软件版本

R 4.6.1 (2026-06-24 ucrt), readr / dplyr / ggplot2 (版本记录见 logs/scripts_sessionInfo_q4.txt) ; Python 3 (Anaconda: matplotlib 3.8.4、numpy 1.26.4、pandas 2.2.2、pymupdf) ; Ensembl REST (rest.ensembl.org 与 grch37.rest.ensembl.org, 2026-09-20 访问) ; NCBI E-utilities (db=snp、db=clinvar) ; gnomAD GraphQL (dataset gnomad_r4) 。 **本机未安装 FastQC** (无 Java) , Q2 因此按作业允许的路线读 snapshot, 并额外用自写脚本从原始读数独立复算。

B. 运行命令

```
# Q2: 从原始读数复算 FastQC 模块 (本机无 Java/FastQC)
D:/anaconda/python.exe scripts/qc_demo_fastq.py # ->
logs/q2_fastqc_independent_audit.txt

# Q4: 四个独立核对 (Ensembl 双装配 / NCBI / gnomAD / VEP)
D:/anaconda/python.exe scripts/verify_variants_external.py # ->
logs/q4_external_verification.txt
D:/anaconda/python.exe scripts/check_ref_alleles.py # ->
logs/q4_ref_allele_check.txt
D:/anaconda/python.exe scripts/vep_check_variants.py # -> logs/q4_vep_check.txt
D:/anaconda/python.exe scripts/verify_population_frequency.py

# Q4: 真实过滤与排序 (R)
"C:/Program Files/R/R-4.6.1/bin/Rscript.exe" scripts/q4_filter_variants.R

# 图
D:/anaconda/python.exe scripts/make_figures.py
```

c. 每条结论对应的日志文件

结论	证据文件
Q2 七个 FastQC 模块的实测值	logs/q2_fastqc_independent_audit.txt
Q3 (示意性) 图与表	figures/Q3_locus_chain.png、 scripts/make_figures.py
Q4 装配混用、基因落点、ClinVar ID 占位符	logs/q4_external_verification.txt
Q4 REF/ALT 与参考碱基不符 (5/12)	logs/q4_ref_allele_check.txt
Q4 VEP 独立注释 (标签复现 2/10)	logs/q4_vep_check.txt
Q4 真实人群频率 / rsID / ClinVar 记录	logs/q4_population_frequency.txt
Q4 过滤与排序的逐步输出	logs/q4_filter_run.txt、 results/q4_shortlist.tsv
讲义与 reading 的引用定位	logs/week4_ppt_text.txt、 logs/week4_reading_text.txt

D. Q4 关键阈值与打分函数 (scripts/q4_filter_variants.R 节选)

```
min_dp <- 20; min_gq <- 30; max_af <- 0.01; require_pass <- TRUE
impact_consequences <- c("stop_gained","frameshift_variant","splice_acceptor_variant",
                          "splice_donor_variant","start_lost","missense_variant")

score_table <- clin_from_table + impact_table + quality_bonus
score_verified <- clin_tier + impact_verified + quality_bonus # 只用通过记录有效性
# 闸门的记录
record_valid <- ref_ok != "NEITHER" & allele_match # REF/ALT 必须存在于命名装配
```

E. 额外图 (QC 证据三联图)

figures/Q2_qc_panel.png (per-base quality 含 p10 线、GC 分布、adapter 随 cycle 上升)